

# EST-46114 Métodos Multivariados

Sesión - Examen Parcial 1 - Soluciones

Juan Carlos Martínez-Ovando

Maestría en Ciencia de Datos





## Pregunta 1.a.

El análisis de componentes principales poblacionales (PPCA) es equivalente al análisis de componentes principales muestrales (SPCA).

*R: No. Mientras que PPCA describe la covariedad poblacional de  $N$  individuos a través de la descomposición espectral de la covarianza de  $p$ -mediciones,  $\mathbf{\Lambda} = \text{diag}\{\lambda_1, \dots, \lambda_p\}$  y  $\mathbf{V} = (\mathbf{v}'_1, \dots, \mathbf{v}'_p)$ , considerando que **no existe incertidumbre en  $\mathbf{\Lambda}$  y  $\mathbf{V}$** ,*

*en SPCA el desconocimiento acerca de la covarianza poblacional es **descrito muestralmente** con  $\mathbf{\Lambda}_n$  y  $\mathbf{V}_n$ , calculadas con  $n$ -observaciones, las cuales pueden:*

- transferir sesgos en los datos
- transferir incertidumbre derivada de información incompleta
- transferir errores derivados del procedimiento de estimación (*metodológico y computacional*)

## Pregunta 1.b.

Los resultados de aplicar PCA sobre estas dos matrices de covarianzas muestrales,

$$\Sigma_1 = \begin{bmatrix} 1 & 0.1 & 0.3 \\ 0.1 & 2 & 0.2 \\ 0.3 & 0.2 & 3 \end{bmatrix}, \text{ y } \Sigma_2 = \begin{bmatrix} 1 & 0.2 & 0.3 \\ 0.2 & 3 & 0.1 \\ 0.3 & 0.1 & 2 \end{bmatrix},$$

respectivamente, son equivalentes.

*No.  $\Sigma_1$  y  $\Sigma_2$  son ambas muy parecidas. Ambas son matrices positivo definidas, en principio.*

## Pregunta 1.b.

*Bajo lo anterior, tendran asociada la misma descomposicion espectral si son derivadas de rotacion de las columnas originales. Ese no es el caso, ya que si*

$$\Sigma_1 = \begin{bmatrix} \sigma_{xx} & & \\ \sigma_{yx} & \sigma_{yy} & \\ \sigma_{zx} & \sigma_{zy} & \sigma_{zz} \end{bmatrix},$$

*observamos que  $\Sigma_2$  **no esta asociada con la rotacion inducida por intercambiar** las variables y y z, i.e.*

$$\Sigma_2 \neq \begin{bmatrix} \sigma_{xx} & & \\ \sigma_{zx} & \sigma_{zz} & \\ \sigma_{yx} & \sigma_{yz} & \sigma_{yy} \end{bmatrix}.$$

## Pregunta 1.b.

*Numericamente tenemos:*

```
Sigma1 <- matrix(c(1,0.1,0.3,  
                  0.1,2,0.2,  
                  0.3,0.2,3),ncol=3,nrow=3)  
Sigma2 <- matrix(c(1,0.2,0.3,  
                  0.2,3,0.1,  
                  0.3,0.1,2),ncol=3,nrow=3)  
Sigma1_eigen <- eigen(Sigma1)  
Sigma2_eigen <- eigen(Sigma2)
```

## Pregunta 1.b.

### Eigenvalores

```
Sigma1_eigen$values
```

```
## [1] 3.0856729 1.9631139 0.9512132
```

```
Sigma2_eigen$values
```

```
## [1] 3.0365310 2.0598371 0.9036319
```

## Pregunta 1.b.

### Eigenvectores

```
Sigma1_eigen$
```

```
##           [,1]      [,2]      [,3]  
## [1,] -0.1487448 -0.03928735  0.98809489  
## [2,] -0.1923881 -0.97896799 -0.06788596  
## [3,] -0.9699803  0.20019537 -0.13805793
```

```
Sigma2_eigen$
```

```
##           [,1]      [,2]      [,3]  
## [1,] -0.1156563 -0.2422244  0.96330212  
## [2,] -0.9849427  0.1534267 -0.07967505  
## [3,] -0.1284970 -0.9580123 -0.25632188
```



## Pregunta 1.c.

Los resultados del modelo de factores (FA) son invariantes a la forma en cómo se modela la media de todas dimensiones originales en un conjunto de datos.

*No. Recordemos que en modelo FA, la incertidumbre de  $\mathbf{X} = (X_1, \dots, X_p)$  se describe con una distribución gaussiana  $p$ -dimensional, donde la **matriz de varianzas y covarianzas** es de la forma*

$$\begin{aligned}\Omega &= \Lambda' \Lambda + \Sigma, \\ &= \mathbb{E}_{N_p} \{ (\mathbf{X} - \boldsymbol{\mu})^2 \},\end{aligned}$$

*siendo*

$$\boldsymbol{\mu} = \mathbb{E}_{N_p}(\mathbf{X}).$$

## Pregunta 1.c.

*En la práctica, en el caso del modelo FA aplicado a las serie de datos de tipos de cambio, vimos que la descomposición en factores está determinada fundamentalmente por la forma de calcular/modelar los niveles medios observacion a observacion.*

## Pregunta 1.d.

Realizar predicciones de  $\mathbf{X} = (X_1, \dots, X_p)$ , no observado, con base en datos  $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ , donde  $\mathbf{x}_n = (x_{1n}, \dots, x_{pn})$  para  $n = 1, \dots, N$ , empleando PCA reduce incertidumbre respecto a realizar la predicción empleando un modelo gaussiano  $p$ -dimensional.

*No necesariamente. Tenemos dos casos:*

**Caso 1)** *Si la estructura de variabilidad en las  $p$ -dimensiones es conocida (ya sea conocida o conocida nula), la predicción de las  $p$ - variables podría realizarse por separado y calcular la predicción conjunta a través de la transformación afín,*

$$\Lambda' \mathbf{X}.$$

**Caso 2)** *Si la estructura de correlación es desconocida, el esfuerzo predictivo de un método y otro es equivalente. Aunque, el esfuerzo computacional en la predicción via PCA es más elevado.*

## Pregunta 1.e.

El resultado en el que después de aplicar PCA a un conjunto de datos se obtiene que la estructura de los datos originales y la de los componentes principales resultante es la misma, es evidencia exclusiva que los datos originales son ortogonales.

*No necesariamente.*

- En el caso **ortogonal**, desde luego, esta aseveración se cumple.
- En el caso funcional, donde las relaciones de las  $p$ -variables originales tienen una estructura compleja (*no euclidiada*, como textos o imágenes), aplicar PCA involucra solo la rotación de las variables originales.

## Pregunta 1.e.

El resultado en el que después de aplicar PCA a un conjunto de datos se obtiene que la estructura de los datos originales y la de los componentes principales resultante es la misma, es evidencia exclusiva que los datos originales son ortogonales.

*No necesariamente.*

- En el caso **ortogonal**, desde luego, esta aseveración se cumple.
- En el caso funcional, donde las relaciones de las  $p$ -variables originales tienen una estructura compleja (*no euclidiada*, como textos o imágenes), aplicar PCA involucra solo la rotación de las variables originales.

## Pregunta 1.f.

La matriz de cargas  $\mathbf{\Lambda}^{(k)}$  del modelo FA con  $k$  factores, aplicado a un vector  $p$ -dimensional de mediciones, incluye toda la información acerca de la estructura de correlación de las  $p$  mediciones.

*No. La matriz  $\mathbf{\Lambda}$  incluye información relevante respecto al comovimiento de las  $p$ -variables, pero no respecto a la **escala** marginal y agregada.*

*La **matriz de covarianzas** es,*

$$\mathbf{\Omega} = \mathbf{\Lambda}\mathbf{\Lambda}' + \mathbf{\Sigma},$$

*mientras que la matriz de correlaciones es*

$$\boldsymbol{\rho} = (\rho_{kj})_{k,j=1}^p$$

*con*

$$\rho_{kj} = \frac{\omega_{kj}}{(\omega_{jj}\omega_{kk})^{1/2}}.$$

## Pregunta 1.g.

Si el número de componentes retenidos aumenta, por ejemplo, de  $m$  a  $(m + 1)$ , las primeras  $m$  componentes del SPCA no habrán de cambiar. Este es también el caso en el modelo de análisis de factores (FA).

*No. En SPCA la reducción de dimensionalidad es arbitraria y no tiene forma de incorporar caso-a-caso la pérdida de información inducida por la reducción de dimensionalidad.*

*En el modelo FA, se incorpora implícitamente a través de  $\mathbf{\Lambda}^{(m)}$  y  $\mathbf{\Sigma}^{(m)}$  la cantidad de información asociada con la reducción de  $p$  a  $m$  dimensiones ( $m \ll p$ ).*

*Por lo que no existe asociación directa entre los componentes  $FA_m$ s anidados.*

## Pregunta 4.a.

En SPCA, ¿cómo podemos recuperar la matriz de covarianzas muestral a partir de los *eigenvectores* y *eigenvectores* muestrales?

*Si  $\mathbf{\Lambda} = \text{diag}\{\lambda_1, \dots, \lambda_p\}$  y  $\mathbf{V} = (\mathbf{v}'_1, \dots, \mathbf{v}'_p)$  son las matrices de eigenvalores y eigenvectores asociados con SPCA, entonces*

$$\mathbf{\Omega} = \mathbf{V}'\mathbf{\Lambda}\mathbf{V}.$$



## Pregunta 4.b.

Si  $\mathbf{X} = (X_1, \dots, X_p)$  denota un vector  $p$ -dimensional en escala original sobre el cual se aplica el modelo FA con  $k$  factores fijos ( $k \ll p$ ). Describe el efecto que tendrá sobre los factores el reescalar cada columna de  $\mathbf{X}$  por  $c_1, \dots, c_p$  valores fijos positivos.

*Si definimos la matriz*

$$\mathbf{C} = \text{diag}\{c_1, \dots, c_p\},$$

*el vector reescalado queda expresado como*

$$\mathbf{Y} = \mathbf{C}\mathbf{X}.$$

Si  $\mathbf{\Lambda}^{(m)}$  y  $\mathbf{\Sigma}^{(m)}$  son las matrices de cargas y dispersiones del modelo FA  $m$ -dimensional para  $\mathbf{X}$ , entonces, al aplicar la transformación afín en  $\mathbf{C}$  sobre

$$\mathbf{X}|\mathbf{f}^{(m)} \sim N_p(\mathbf{x}|\mathbf{\Lambda}^{(m)}\mathbf{f}^{(m)}, \mathbf{\Sigma}^{(m)}),$$

por lo que

$$\mathbf{\Omega}_Y = \mathbf{C}\mathbf{\Lambda}^{(m)}\mathbf{\Lambda}^{(m)'}\mathbf{C} + \mathbf{C}\mathbf{\Sigma}^{(m)}\mathbf{C}.$$

## Pregunta 4.b.

*Es decir, las matrices de cargas y dispersiones para  $\mathbf{Y}$  son ahora,*

$$\begin{aligned}\Lambda_{\mathbf{Y}}^{(m)} &= \mathbf{C}\Lambda^{(m)} \\ \Sigma_{\mathbf{Y}}^{(m)} &= \mathbf{C}\Sigma^{(m)}\mathbf{C}.\end{aligned}$$

*Así, FA es prácticamente no afectado por cambio de escala en las variables originales.*

*Es decir, el modelo FA sobre matrices de correlación y sobre matrices de covarianzas arroja resultados análogos. No así PCA, por cierto.*

## Pregunta 4.c.

Desarrolla la expresión para la matriz de covarianzas en el modelo FA si se considera que los factores puedan estar correlacionados.

*Este es un problema importante. Lo vimos parcialmente en el caso de volatilidad estocástica; **pero lo examinaremos con detalle el martes entrante.***

*Especificación, para  $\mathbf{X}_t$ , con  $t = 1, \dots, T$ , y  $m$  fijo,*

$$\begin{aligned}\mathbf{X}_t | \mathbf{f}_t^{(m)} &\sim N_p(\mathbf{x} | \mathbf{\Lambda}^{(m)} \mathbf{f}_t^{(m)}, \mathbf{\Sigma}^{(m)}) \\ \mathbf{f}_t &\sim N_m(\mathbf{f} | \mathbf{0}, \mathbf{G}^{(m)}),\end{aligned}$$

*con  $\mathbf{G}^{(m)}$  ( $m \times m$ ) no diagonal, pero simétrica positivo definida.*

## Pregunta 4.c.

*La forma de la relación es*

$$\mathbf{\Omega} = \mathbf{\Lambda}^{(m)} \mathbf{G}^{(m)} \mathbf{\Lambda}^{(m)'} + \mathbf{\Sigma}^{(m)}.$$

Vean:

- [est46114\\_2019a\\_parcial\\_1\\_soluciones\\_auxiliar2.pdf](#) (artículo)  
Referencia: Tucker (1940) "The role of correlated factors in factor analysis", *Psychometrika*.
- [est46114\\_2019a\\_parcial\\_1\\_soluciones\\_auxiliar3.pdf](#) (desarrollo)

## Preguntas 2 y 3

*Revisen laboratorio markdown...*

est46114\_2019a\_parcial\_1\_soluciones\_auxiliar1.pdf

# Table of Contents

Pregunta 1

Pregunta 4

Preguntas 2 y 3