

# EST-46114 Métodos Multivariados y Datos Categóricos

Sesion 02 - Distribucion Gaussiana Multivariada

Juan Carlos Martinez-Ovando

Maestria en Ciencia de Datos





# Objetivos

- Entender el uso de los modelos gaussianos en el analisis de datos multivariados.
- Estudiar propiedades teorico/practicas de la distribucion gaussiana multidimensional.
- Revisar procedimientos de inferencia y prediccion empleando estos modelos.

# Usos

- La distribución gaussiana *brinda* la posibilidad de estudiar **covariabilidad**, **simetría estocástica** y **simultaneidad** en fenómenos multidimensionales.
- Provee un **marco parcimonioso** de modelación.
- Brinda una **plataforma de extensión** de modelos sofisticados.

# Limitaciones

- Solamente se atiende a los **primeros dos momentos** de la variabilidad entre dimensiones multiples.

## Caso Univariado

Iniciamos con la distribución gaussiana unidimensional, acompañada por una función de densidad de probabilidad,

$$f(x|\mu, \lambda) = (2\pi)^{-1/2} \lambda^{1/2} \exp \left\{ -(\lambda/2)(x - \mu)^2 \right\},$$

con soporte en  $\mathcal{X} = \mathbb{R}$ .

- $\mu$  es parámetro de localización.
- $\lambda$  es parámetro de dispersión (**precision**, en este caso).
- El espacio paramétrico para  $(\mu, \lambda)$  es

$$\mathbb{R} \times \mathbb{R}_+.$$

## Caso multivariado

El caso multivariado es una extension del univariado para  $\mathbf{x} = (x_1, \dots, x_p)$ , pero que toma en cuenta las **interacciones** entre las  $(x_i)_{i=1}^p$ . Esta tiene una funcion de densidad conjunta dada por,

$$f(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Lambda}) = (2\pi)^{-p/2} \det(\boldsymbol{\Lambda})^{1/2} \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Lambda} (\mathbf{x} - \boldsymbol{\mu}) \right\},$$

con soporte en  $\mathbb{R}^p$  para  $\mathbf{x}$ .

- Espacio parametral para  $\boldsymbol{\mu}$  es  $\mathbb{R}^p$
- Espacio parametral para  $\boldsymbol{\Lambda}$  es  $\mathcal{M}_p$  –espacio de todas las matrices de dimension  $p \times p$  positivo definidas y simetricas–.
- Numero de **parametros independientes** en  $\boldsymbol{\mu}$  es igual a  $p$ , mientras que el numero de parametros independientes en  $\boldsymbol{\Lambda}$  es igual a  $p(p+1)/2$ .

# Propiedad P1

Si  $\mathbf{X} \sim N(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Lambda})$  entonces,

**P1.** Cualquier combinacion lineal de  $\mathbf{X}$  es gaussiana multivariada, i.e. para todo  $A$  matriz de dimension  $q \times p$  y  $c$  vector de dimension  $q \times 1$ , tales que

$$\boldsymbol{\mu}_y = A\boldsymbol{\mu} + c,$$

y

$$\boldsymbol{\Lambda}_y = A\boldsymbol{\Lambda}A',$$

se sigue que

$$\mathbf{Y} \sim N(\mathbf{y}|\boldsymbol{\mu}_y, \boldsymbol{\Lambda}_y),$$

con soporte para  $\mathbf{y}$  dado por  $\mathbb{R}^q$ .



# Propiedad P1

## Comentarios

- Esta propiedad es útil ya que muchos problemas (contraste de hipótesis, agregación, construcción de portafolios, proyecciones, etc.) pueden expresarse como una **transformación afin (transformación lineal anterior)**.

## Propiedad P2

Si  $\mathbf{X} \sim N(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Lambda})$  entonces,

**P2.** Cualquier sub-conjunto de  $\mathbf{X}$ , formado por subselecciones este vector, tiene una distribucion gaussiana multivariada asociada, i.e. si

$$\mathbf{X}_s = (X_{s(1)}, \dots, X_{s(q)}),$$

es un subconjunto de  $\mathbf{X}$ , con  $q \leq p$ , para un subconjunto de indices

$$(s(1), \dots, s(q))$$

de

$$(1, \dots, p).$$

## Propiedad P2

Se sigue que

$$\mathbf{X}_s \sim N(\mathbf{x}_s | \boldsymbol{\mu}_s, \boldsymbol{\Lambda}_s),$$

donde

$$\boldsymbol{\mu}_s = (\mu_{s(1)}, \dots, \mu_{s(q)}),$$

y

$$\boldsymbol{\Lambda}_s = (\lambda_{s(i)s(j)})_{i,j=1}^q.$$

### Comentarios

- Esta propiedad permite relaizar estudios conjuntos o marginales reducidos a partir del mismo procedimiento, mediante la implementacion del proceso de marginalizacion involucrado.

## Propiedad P3

Si  $\mathbf{X} \sim N(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Lambda})$  entonces,

**P3.** Si un subconjunto de  $\mathbf{X}$  no esta correlacionado, entonces las variables de ese conjunto son *estocasticamente independientes*, i.e. si

$$(X_i, X_j),$$

son dos dimensiones de  $\mathbf{X}$  (con  $i, j < p$ ), tales que

$$\lambda_{i,j} = 0,$$

se sigue que

$$X_i \text{ y } X_j,$$

son independientes estocasticamente con,

$$f(x_i, x_j | \mu_i, \mu_j, \lambda_{ii}, \lambda_{jj}, \lambda_{ij}) = N(x_i | \mu_i, \lambda_{ii}) \times N(x_j | \mu_j, \lambda_{jj}).$$

# Propiedad P3

## Comentarios

- A partir de esta propiedad podemos **estudiar relaciones de dependencia lineal** entre dimensiones de un conjunto de datos o problemas multidimensionales.
- Consideremos que las dependencias lineales se refieren *simultaneidad* mas no a *causalidad*.

## Propiedad P4

Si  $\mathbf{X} \sim N(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Lambda})$  entonces,

**P4.** Si un  $A$  y  $B$  son dos matrices de dimension  $(q \times p)$  tales que

$$A\boldsymbol{\Sigma}B' = \mathbf{0},$$

de dimension  $q \times q$ , entonces

## Propiedad P4

Se sigue que las variables,

$$\mathbf{Y}_A = \mathbf{A}\mathbf{X} \text{ y } \mathbf{Y}_B = \mathbf{B}\mathbf{X},$$

son **estocasticamente independientes**.

### Comentarios

- A partir de esta propiedad, podemos entender que las estructuras de simultaneidad entre variables pueden modificarse a través de operaciones algebraicas teoricas.
- Esta propiedad es crucial, porque podemos **modificar patrones subyacentes de dependencia/simetria estocastica** aplicando transformaciones lineales.

## Propiedad P5

**P5.** (Distribuciones condicionales). Si

$$\mathbf{X} = (\mathbf{X}_1, \mathbf{X}_2),$$

donde ambos componentes son de dimension  $p_1$  y  $p_2$  respectivamente, (lo anterior se conoce como una particion de dos componentes de  $\mathbf{X}$ ), con  $p = p_1 + p_2$ , se sigue:

- Los parametros del modelo tambien estan particionados de la siguiente forma,

$$\boldsymbol{\mu} = (\boldsymbol{\mu}_1, \boldsymbol{\mu}_2),$$

$$\boldsymbol{\Lambda} = \begin{pmatrix} \boldsymbol{\Lambda}_{11} & \boldsymbol{\Lambda}_{12} \\ \boldsymbol{\Lambda}_{21} & \boldsymbol{\Lambda}_{22} \end{pmatrix}.$$



## Propiedad P5

- La *distribucion marginal* de  $\mathbf{X}_i$  (para  $i = 1, 2$ ) es

$$\mathbf{X}_i \sim N(\mathbf{x}_i | \boldsymbol{\mu}_i, \boldsymbol{\Lambda}_i).$$

## Propiedad P6

Si  $\mathbf{X}$  es particionado en  $\mathbf{X}_1$  y  $\mathbf{X}_2$ , se sigue:

**P6.** La distribución condicional de  $\mathbf{X}_2$  dado  $\mathbf{X}_1 = \mathbf{x}_1$  es gaussiana multivariada, con

$$\mathbf{X}_2 | \mathbf{X}_1 = \mathbf{x}_1 \sim N(\mathbf{x}_2 | \boldsymbol{\mu}_{2|1}, \boldsymbol{\Lambda}_{2|1}),$$

donde

$$\boldsymbol{\mu}_{2|1} = \boldsymbol{\mu}_2 + \boldsymbol{\Lambda}_{21} \boldsymbol{\Lambda}_{11}^{-1} (\mathbf{x}_1 - \boldsymbol{\mu}_1),$$

y

$$\boldsymbol{\Lambda}_{2|1} = \boldsymbol{\Lambda}_{22} - \boldsymbol{\Lambda}_{21} \boldsymbol{\Lambda}_{11}^{-1} \boldsymbol{\Lambda}_{12}.$$

# Propiedad P6

## Comentarios

- Esta propiedad es de **simetria estocastica**, en el sentido que la distribucion condicional de  $\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2$  es analoga.
- Esta propiedad es fundamental para entender el modelo de regresion multiple.

# Descomposicion I

**Estructura espectral.-** Una matrix  $P$  de dimension  $p \times p$  es **ortogonal** si

$$PP' = P'P = I.$$

**P7.** Una matrix  $A$  simetrica de dimension  $p \times p$  puede reexpresarse como

$$A = P\Lambda P',$$

donde

- $\Lambda = \text{diag}\{\lambda_1, \dots, \lambda_p\}$  de *eigenvalores*
- $P$  es una matriz ortogonal de *eigenvectores* columna.

# Descomposicion I

## Intuicion

- La matriz de *eigenvalores* representa *rotaciones* de coordenadas.
- La matriz de *eigenvalores* representan *contracciones* o *expansiones* de coordenadas.

## Descomposicion II

**Acerca de determinantes.-** Bajo la descomposicion espectral de  $\mathbf{\Lambda}^{-1}$  se sigue

$$\det(\mathbf{\Lambda}^{-1}) = \prod_{j=1}^p \phi_j.$$

Esto es analogo a calcular los determinantes de  $\mathbf{\Lambda}$ , que estan determinados por

$$\det(\mathbf{\Lambda}) = \prod_{j=1}^p \phi_j^{-1},$$

por ser  $\mathbf{\Lambda}$  una matriz positivo definida y simetrica.

# Descomposicion II

## Intiucion

- Los **eigenvalores** de  $\mathbf{\Lambda}^{-1}$  nos indican el grado de variabilidad de cada dimension (por separado) en  $\mathbf{X}$
- Los valores  $\phi_j$  nos indican que tan expandida/contraida es la distribucion en esta dimension
- El factor  $\det(\mathbf{\Lambda}^{-1})$  puede verse como un factor de expansion/contraccion de la distribucion gaussiana conjunta.

# Visualizacion

La **grafica de contornos** nos permiten visualizar distribuciones gaussianas de dos dimensiones (i.e. es una representacion de graficas en 3D).

Los *contornos* se obtienen como *rebanadas* de la densidad conjunta en 2D, y representan **areas cuantilicas** del soporte  $\mathcal{X}$  para un nivel  $0 < c < 1$ .

Las lineas representan la coleccion de valores de  $\mathbf{x}$  que comparten el mismo nivel de  $N(\mathbf{x}|\mu, \Lambda)$ .

**Calculo.-** Los contornos se definen en terminos de  $\Lambda$  y  $P$  como **elipsoides**

$$||\Lambda^{1/2}(\mathbf{x} - \mu)|| = c^2,$$

siendo centradas en

$$\mu,$$


y con ejes en la direccion

$$\sqrt{\lambda_j p_j}.$$




# Visualización I

## Caso: Independencia estocastica/simetria




## Visualizacion II

**Caso: Dependencia positiva.**



## Visualizacion III

**Caso: Dependencia negativa.**



# Verosimilitud

La función de verosimilitud para  $(\mu, \Lambda)$  condicional en un conjunto de datos,  $\mathbf{x}_1, \dots, \mathbf{x}_n$  se calcula como la densidad conjunta de los  $n$  datos, **bajo el supuesto de independencia en las observaciones**, de la forma

$$\begin{aligned} l(\mu, \Lambda | \mathbf{x}_1, \dots, \mathbf{x}_n) &= \prod_i N(\mathbf{x}_i | \mu, \Lambda) \\ &\propto |\Lambda|^{n/2} \exp \left\{ -\frac{1}{2} \sum_i (\mathbf{x}_i - \mu)' \Lambda (\mathbf{x}_i - \mu) \right\} \\ &\propto |\Lambda|^{n/2} \exp \left\{ -\frac{1}{2} \text{tr} (\Lambda^{-1} (S + dd')) \right\}, \end{aligned}$$

donde  $d = \bar{\mathbf{x}} - \mu$  y  $S$  es la matriz de covarianzas muestral.

# Ejercicio

*La ultima linea de la ecuacion anterior es un ejercicio a casa. Consideren la complesion del cuadrado que esta en el documento suplementario de esta sesion (adjunto, escrito a mano).*

# Estimacion I

## Caso: Estimacion frecuentista.

A partir de las ecuaciones anteriores, podemos encontrar el **estimador maximo verosilil** de  $\mu$  y  $\Lambda$ , dados por

$$\hat{\mu} = \bar{x},$$

y

$$\hat{\Lambda} = \left( \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})' \right)^{-1}.$$

*El ultimo estimador corresponde a la matriz inversa de covarianzas muestral.*

La distribución gaussiana multidimensional es una buena herramienta para:

- Describir la aleatoriedad/desconocimiento en fenómenos multidimensionales.
- Su buen uso descansa en el supuesto de **simetría elíptica**.
- En la práctica, la **simetría elíptica** puede corroborarse contrastando *gráficas de dispersión de datos* con las curvas de nivel de **un modelo gaussiano multidimensional**.
- A partir de esto, muchos procesos inferenciales (incluyendo predicción, descomposiciones espectrales, contraste de hipótesis) pueden plantearse con esto.

# Ejercicios

1. Consideren los datos `data(swiss)` de provincias en Suiza.
2. Calculen el EMV de  $\mu$  y  $\Lambda$  en la distribución gaussiana.
3. Identifiquen la estructura de *simetria eliptica* y grafiquen tales relaciones en parejas de variables.



# La siguiente sesion

Revisaremos como hacer:

1. Inferencia frecuentista (en parametros y transformaciones).
2. Inferencia bayesiana (en parametros y trasnformaciones).
3. Prediccion.
4. Modificaciones de distribuciones.

# Lecturas complementarias

- Complecion de cuadrados en la distribucion gaussiana.  
`est46114_s02_suplemento1.pdf`

# Lecturas extendidas

- Dawid, P.A. (1981) “Matrix-Variate Distribution Theory: Notational Considerations and a Bayesian Application”, *Biometrika*.  
`est46114_s02_suplemento2.pdf`

# Table of Contents