

EST-46114 Métodos Multivariados y Datos Categóricos

Sesion 03 - Inferencia en la Distribucion Gaussiana Multivariada - Parte 1

Juan Carlos Martinez-Ovando

Maestria en Ciencia de Datos



Objetivos

- Revisaremos el procedimiento de estimacion puntual frecuentista y bayesiano de los parámetros de la distribución gaussiana multidimensional.
- Revisaremos como hacer predicción con ambos enfoques inferenciales.
- Implicaciones inferenciales pertinentes en ambos escenarios.

Clase de distribuciones

Como mencionamos, cuando nos referimos al modelo gaussiano (y a cualquier modelo de probabilidad) nos estamos refiriendo en realidad a clases modelos, \mathcal{F} , dadas por

$$\mathcal{F} = \{F(\cdot|\theta) : F(\cdot|\theta) \text{ es una medida de probabilidad para todo } \theta\},$$

con $\theta \in \Theta$ espacio parametral y *soporte* \mathcal{X} .

*Usualmente se supone el cumplimiento de **condiciones de regularidad**.*

Observacion

- Cada valor de θ define un modelo de probabilidad $F(\cdot|\theta)$.

Clase gaussiana de distribuciones

Para $X = (X_1, \dots, X_p)$ vector p -dimensional, suponemos que es *modelado por la clase de distribuciones gaussianas* \mathcal{F} si su función de densidad es,

$$f(x|\boldsymbol{\mu}, \boldsymbol{\Lambda}) = (2\pi)^{-p/2} |\boldsymbol{\Lambda}|^{1/2} \exp \left\{ -\frac{1}{2} (x - \boldsymbol{\mu})' \boldsymbol{\Lambda} (x - \boldsymbol{\mu}) \right\},$$

para todo x en \mathcal{X} , siendo $\boldsymbol{\Lambda}$ la matrix de precisión.

Datos

Consideremos ahora que contamos con n datos recolectados,

$$\text{datos} = \{x_1, \dots, x_p\},$$

con x_j s vectores p -dimensionales. Típicamente renglones de una matriz de datos, e.g.

```
data(swiss)
swiss[1,]
```

```
##           Fertility Agriculture Examination Education Catholic
## Courtelary      80.2           17           15           12      9.96
##           Infant.Mortality
## Courtelary           22.2
```

Inferencialmente buscaremos el modelo particular en \mathcal{F} que *sea mas compatible* con los datos.

Dos paradigmas

A. Frecuentista

B. Bayesiano

Ambos basados en el principio de verosimilitud, i.e. la compatibilidad de los datos y los modelos en \mathcal{F} se mide con la función

$$l(\boldsymbol{\mu}, \boldsymbol{\Lambda} | \text{datos}) = f(x_1, \dots, x_n | \boldsymbol{\mu}, \boldsymbol{\Lambda}).$$

Es decir,

$$l(\boldsymbol{\mu}, \boldsymbol{\Lambda} | \text{datos}) = \begin{cases} \prod_{i=1}^n f(x_i; \boldsymbol{\mu}, \boldsymbol{\Lambda}) & , \text{ (frecuentista),} \\ \prod_{i=1}^n f(x_i | \boldsymbol{\mu}, \boldsymbol{\Lambda}) & , \text{ (bayesiano).} \end{cases}$$

Estimacion frecuentista

El *modelo mas compatible*, bajo el enfoque frecuentista, es

$$F(\cdot | \boldsymbol{\mu}^*, \boldsymbol{\Lambda}^*),$$

tal que

$$\boldsymbol{\mu}^*, \boldsymbol{\Lambda}^* = \arg \max_{\boldsymbol{\mu}, \boldsymbol{\Lambda}} l(\boldsymbol{\mu}, \boldsymbol{\Lambda} | \text{datos}).$$

Es decir,

$$\begin{aligned}\boldsymbol{\mu}^* &= \bar{\mathbf{x}}, \\ \boldsymbol{\Lambda}^* &= \mathbf{S}^{-1},\end{aligned}$$

con $\mathbf{S} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})'$.

Se obtiene de manera analoga al caso univariado (revisen las lecturas complementarias).

Estimacion bayesiana I

En el caso bayesiano, se considera que junto con los datos se dispone de fuentes complementarias de informacion reflejadas en la distribucion prior con soporte en la clase de modelos \mathcal{F} (a.k.a. espacio parametral Θ), con densidad,

$$q(\boldsymbol{\mu}, \boldsymbol{\Lambda} | \text{informacion complementaria}).$$

- Como la verosimilitud, la funcion $q(\cdot)$ sirve para cuantificar **grados de acertividad** que *creamos convenientes*.
- En un momento veremos formas de especificar $q(\cdot)$.

Estimacion bayesiana II

La informacion consolidad de los datos y complementaria se **consolida** en el producto

$$l(\boldsymbol{\mu}, \boldsymbol{\Lambda}|\text{datos}) \times q(\boldsymbol{\mu}, \boldsymbol{\Lambda}|\text{complementaria}).$$

Estimacion bayesiana II

Generalmente, resulta que este producto es una medida de probabilidad para $(\boldsymbol{\mu}, \boldsymbol{\Lambda})$, con densidad dada por

$$q(\boldsymbol{\mu}, \boldsymbol{\Lambda}|\text{complementaria}) \propto l(\boldsymbol{\mu}, \boldsymbol{\Lambda}|\text{datos})q(\boldsymbol{\mu}, \boldsymbol{\Lambda}|\text{complementaria}),$$

siendo constante de normalizacion,

$$\int \int l(\boldsymbol{\mu}, \boldsymbol{\Lambda}|\text{datos})q(\boldsymbol{\mu}, \boldsymbol{\Lambda}|\text{complementaria})d\boldsymbol{\mu}d\boldsymbol{\Lambda}.$$

Priors

Difusa (no informativa)

$$q(\boldsymbol{\mu}, \boldsymbol{\Lambda}) \propto |\boldsymbol{\Lambda}|^{1/2}.$$

Conjugada (parcialmente informativa)

$$q(\boldsymbol{\mu}, \boldsymbol{\Lambda}) = N(\boldsymbol{\mu} | \boldsymbol{m}_0, s_0 \boldsymbol{\Lambda}) W(\boldsymbol{\Lambda} | a_0, \boldsymbol{B}_0),$$

donde s_0 y a_0 son escalares positivos, \boldsymbol{m}_0 es un vector p -dimensional y \boldsymbol{B}_0 es una matriz simetrica $p \times p$ -dimensional.

- $N(\boldsymbol{\mu} | \boldsymbol{m}_0, s_0 \boldsymbol{\Lambda})$ - Densidad gaussiana p -dimensional
- $W(\boldsymbol{\Lambda} | a_0, \boldsymbol{B}_0)$ - Densidad Wishart p -dimensional (vean lecturas complementarias)

*Los valores $(\boldsymbol{m}_0, s_0, a_0, \boldsymbol{B}_0)$ se conocen como **hiperparametros** y reflejan (de alguna forma) la informacion complementaria a los datos.*

Estimacion bayesiana III

Como mencionamos, el aprendizaje bayesiano con datos y complemento se consolida con $q(\boldsymbol{\mu}, \boldsymbol{\Lambda} | \text{datos y complemento})$.

Caso conjugado:

$$q(\boldsymbol{\mu}, \boldsymbol{\Lambda} | \text{datos y complemento}) = N(\boldsymbol{\mu} | \mathbf{m}_n, s_n \boldsymbol{\Lambda}) W(\boldsymbol{\Lambda} | a_n, \mathbf{B}_n),$$

con,

$$\begin{aligned}\mathbf{m}_n &= \frac{s_0 \mathbf{m}_0 + n \bar{\mathbf{x}}}{s_n}, \\ s_n &= s_0 + n, \\ a_n &= a_0 + \frac{n}{2}, \\ \mathbf{B}_n &= \mathbf{B}_0 + \frac{n}{2} \left(S + \frac{s_0}{s_n} (\bar{\mathbf{x}} - \mathbf{m}_0)(\bar{\mathbf{x}} - \mathbf{m}_0)' \right),\end{aligned}$$

donde,

$$S = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})'.$$

Estimacion bayesiana IV

Para μ

$$\mu^{**} = m_n.$$

Para Λ

$$\Lambda^{**} = B_n^{-1}.$$

- *Salvo que la prior sea suficientemente distinta de la verosimilitud, μ^* y μ^{**} no deberan diferir significativamente.*
- *Lo mismo aplica a Λ .*

Estimacion bayesiana IV

Para μ

$$\mu^{**} = m_n.$$

Para Λ

$$\Lambda^{**} = B_n^{-1}.$$

- *Salvo que la prior sea suficientemente distinta de la verosimilitud, μ^* y μ^{**} no deberan diferir significativamente.*
- *Lo mismo aplica a Λ .*

Frecuentista vs bayesiano I

La distincion del paradigma bayesiano reside en:

- a. Capacidad de incorporar informacion complementaria
- b. Cuantificar probabilisticamente diferentes modelos probabilisticos consolidando informacion de datos y complemento

Frequentista vs bayesiano I

Usando gaussian.posterior

```
# Frequentista
```

```
mstar <- colMeans(data)
Lstar <- solve(cov(swiss))
mstar
```

##	Fertility	Agriculture	Examination	Education
##	70.14255	50.65957	16.48936	10.97872
##	Catholic	Infant.Mortality		
##	41.14383	19.94255		

```
# Bayesiano
```

```
m2star <- t(output[[1]])
L2star <- solve(output[[4]])
m2star
```

##	Fertility	Agriculture	Examination	Education	Catholic	Infant.Mor
## [1,]	68.68125	49.60417	16.14583	10.75	40.28667	19

Frecuentista vs bayesiano II

Los estimadores de las precisiones si pueden diferir (esta es una distincion muy importante).

```
Lstar[1:4,1:4]
```

##		Fertility	Agriculture	Examination	Education
##	Fertility	0.021852286	0.003761084	0.005638070	0.019032031
##	Agriculture	0.003761084	0.005075664	0.004886445	0.007566829
##	Examination	0.005638070	0.004886445	0.059201951	-0.019558373
##	Education	0.019032031	0.007566829	-0.019558373	0.046589397

```
L2star[1:4,1:4]
```

##		Fertility	Agriculture	Examination	Education
##	Fertility	5.600515e-04	-1.257432e-05	-1.256250e-04	0.0004243553
##	Agriculture	-1.257432e-05	1.350104e-04	3.640363e-05	0.0001418069
##	Examination	-1.256250e-04	3.640363e-05	2.148985e-03	-0.0012095659
##	Education	4.243553e-04	1.418069e-04	-1.209566e-03	0.0015777335

Implicaciones inferenciales I

Error de estimacion

Frecuentista

Regiones (intervalos) de confianza - **Clases de equivalencia**

Bayesiano

Regiones de credibilidad - **No clases de equivalencia**

[Incorporen graficas de verosimilitud y posterior marginales.]

Ejercicios

1. Revisen los calculos de la distribucion posterior de (μ, Λ) empleando $q(\cdot)$ difusa.
2. Consideren los datos `data(swiss)` de provincias en Suiza. La descripcion de los datos esta en esta liga.
3. Estudien la implementacion en R de las distribuciones Wishart, normal y Student multivariadas. Vean las siguientes ligas:

Liga Wishart

Liga normal y t

En la siguiente sesion

Revisaremos como hacer:

1. Revisaremos las implicaciones de modelacion para responder problemas inferenciales espcificos sobre μ y sobre Λ .

Lecturas complementarias

- Martinez-Ovando (2016) "Paradigma Bayesiano de Inferencia (Resumen de Teoria)", *Notas de clase EST-46114*. (De momento, no presten atencion a la descripcion de los metodos de simulacion transdimensionales.)
est46114_s03_suplemento2.pdf
- Murphy (2007) "Conjugate Bayesian analysis of the Gaussian distribution".
Mimeo. est46114_s03_suplemento2.pdf
- Press (2005). "Applied multivariate analysis, using Bayesian and frequentist methods of inference." Dover Pub. (Capitulo 4.)

Table of Contents